

Fachkonzept

Backend-Architektur Reflecta

AI-driven Journal & Reflection Assistant

Verfasser: Bilal El Hasnaoui (9333793), Simon Lademann (4898928)

1. Zielsetzung der Anwendung

1.1 Hauptfunktionen

- Journal-Management: Erstellen, Lesen, Aktualisieren und Löschen tagesbezogener Einträge mit quantitativen Befindlichkeits-Skalen (Sentiment, Sleep, Stress, Social Engagement; jeweils 1-5).
- Zielverwaltung: Pflege persönlicher Ziele mit Kategorie, Priorität, Zieldatum und Fortschritts-Tracking.
- KI-Anreicherung: Automatische Analyse von Journal-Einträgen durch ein LLM (Aktivitäten-Extraktion, Sentiment-Tagging, Zielzuordnung, Formatierung).
- Analytics: Berechnung von Zeitreihen-Trends, Durchschnittswerten, Korrelationen und KI-generierten Zusammenfassungen.
- Konversationelle Assistenz: Kontextbezogener Chatbot mit Zugriff auf Ziele und letzte Einträge sowie geführte Reflexionsfragen.
- Goal Recommendations: KI-basierte Empfehlung neuer Ziele auf Basis aktueller Journal-Inhalte.
- Administrationsbereich: System-Statistiken zu Nutzerzahl, AI-Aufrufen und Erfolgsraten.

1.2 Kernprozesse

1.2.1 Journal-Eintrag erfassen und anreichern

Der Benutzer erfasst einen Eintrag mit Titel, Datum, Freitext und vier optionalen Skalen-Werten. Nach dem synchronen Persistieren startet ein Background-Task, der das LLM mit dem Inhalt und den Zielen des Nutzers aufruft. Das LLM liefert formatierten Inhalt, eine Aktivitätsliste, eine Sentiment-Liste sowie eine Liste verknüpfter Ziel-IDs zurück. Diese werden in den Eintrag zurückgeschrieben.

1.2.2 Ziele führen

Der Benutzer legt Ziele mit Pflichtfeldern Titel, Typ, Kategorie und Priorität sowie optionalen Feldern Beschreibung und Zieldatum an. Ziele können explizit aktualisiert werden, ihr Fortschrittswert (progress) wird im aktuellen Stand jedoch nicht automatisch fortgeschrieben (siehe Kapitel 9, offene Punkte).

1.2.3 Analytics und Insights

Der Benutzer ruft Trends, Durchschnitte, Korrelationen oder eine generative Zusammenfassung für einen wählbaren Zeitraum ab. Korrelationen und Summaries werden mit einer TTL von 24 Stunden im AnalyticsCache zwischengespeichert und im Hintergrund neu berechnet, wenn der Cache nicht aktuell ist.

2. Systemübersicht

2.1 Architekturüberblick

Das Reflecta-Backend folgt einer klassischen, geschichteten Backend-Architektur (Layered Architecture) auf Basis von FastAPI. Eingehende HTTP-Anfragen werden durch Router-Komponenten entgegengenommen, an Service-Schichten delegiert und über CRUD-Funktionen mit der Datenhaltungsschicht verbunden. Querschnittsthemen wie Authentifizierung, AI-Aufrufe und Analytics-Berechnungen sind als eigenständige Service-Module gekapselt.

2.1.1 Schichtenmodell

Schicht	Verantwortung	Artefakte im Code
Presentation / API	HTTP-Routing, Request-/Response-Modelle, Auth-Dependencies, Background-Task-Anstoß	app/routes/*.py
Application / Service	Fachliche Orchestrierung, AI-Integration, Analytics-Berechnung, Caching	app/services/*.py
Domain Model	Datenstrukturen, Validierung, Enums (Pydantic)	app/models/*.py
Persistence / CRUD	Datenbankzugriffe, ORM-Operationen	app/db/crud/*.py, app/db/database.py
Cross-Cutting	Auth (Cognito + JWT), AI-Client, Logging, Utils	app/auth/*, app/services/ai_client.py, app/utils/*

2.2 Komponentenübersicht

2.2.1 Backend-Komponenten

- `main.py`: Anwendungs-Bootstrap, CORS-Middleware, Router-Registrierung, Lifespan-Hook für Schema-Erstellung.
- `auth/cognito.py`: Cognito-JWT-Verifikation mit JWKS-Cache (TTL 1h).
- `auth/dependencies.py`: `get_current_user` / `get_current_admin` als FastAPI-Dependencies. Just-in-Time User-Provisioning bei erstem Login.
- `routes/`: Endpoint-Definitionen für `auth`, `journal`, `goal`, `chatbot`, `analytics`, `admin`.
- `db/database.py`: Engine, SessionLocal, SQLAlchemy-Modelle (`User`, `JournalEntry`, `Goal`, `AnalyticsCache`, `AIUsageLog`) und Association-Tabelle `journal_goal_association`.
- `db/crud/`: Separierte CRUD-Operationen für `Journal`, `Goal`, Hilfsfunktionen.
- `services/ai_client.py`: Zentralisierter AI-Adapter mit Provider-Auswahl, Retry-Logik (Exponential Backoff), Usage-Logging.
- `services/gemini_agent.py`: Fachliche AI-Funktionen (`analyze_entry`, `recommend_goals`, `generate_journal_question`, `enhance_goal_description`, `summarize_journal_entries`, `generate_correlation_insights`).
- `services/gemini_chatbot.py`: Kontextbezogener Chatbot mit System-Prompt und Nutzerkontext.
- `services/analytics.py`: `AnalyticsService` mit Methoden für Trends, Averages, Korrelationen, Streak-Berechnung.

- models/: Pydantic-Schemas für Eingaben, Ausgaben und Enums.

2.3 Kommunikationsflüsse

2.3.1 Externe Kommunikation

- Client (Web-Frontend localhost:3000 laut CORS-Whitelist) -> Backend via REST/HTTPS.
- Backend -> AWS Cognito IdP via HTTPS (JWKS-Abruf).
- Backend -> AI-Provider (Gemini- oder z.ai-API, OpenAI-kompatibel) via HTTPS.

2.3.2 Interne Kommunikation

- Synchron: HTTP-Request -> Router -> Service/CRUD -> Datenbank -> Response.
- Asynchron via BackgroundTasks: Journal-Anreicherung nach POST/PUT, Cache-Refresh nach Analytics-Abfragen.
- Cross-Cutting: Jeder AI-Aufruf erzeugt einen Eintrag in der Tabelle ai_usage_logs.

2.4 Architekturprinzipien

- Separation of Concerns: klare Trennung Routes / Services / CRUD / Models.
- Dependency Injection via FastAPI Depends() für DB-Session und Auth-Kontext.
- Stateless API: keine Server-Sessions, Authentifizierung pro Request über Bearer-Token.
- Domain-orientierte Modulgliederung statt funktional flacher Struktur.
- Provider-Abstraktion: AI-Client erlaubt Wechsel zwischen Gemini und z.ai per Environment-Variable.
- Fail-Fast bei Auth-Fehlern, graceful Degradation bei AI-Fehlern (Logging, keine Request-Blockade).

3. API-Endpoint-Konzept

3.1 Globale API-Eigenschaften

- Base URL (lokal): `http://127.0.0.1:8000`
- OpenAPI / Swagger UI: `http://127.0.0.1:8000/docs`
- Content-Type: `application/json`
- Authentifizierung: OAuth2 Bearer Token (JWT aus AWS Cognito), Verifikation gegen JWKS.
- DEV_MODE: Bei Umgebungsvariable `DEV_MODE=true` wird die Authentifizierung umgangen und ein synthetischer 'dev-user' verwendet (siehe Kapitel 7 / 9, Sicherheitshinweis).
- CORS: Whitelisted Origin `http://localhost:3000`, alle Methoden und Header erlaubt, Credentials aktiviert.
- Fehlerantworten: FastAPI-Standard mit JSON-Body `{ "detail": "..."}.`

3.2 Endpoint-Übersicht

Methode	Pfad	Zweck
GET	/	Healthcheck / Welcome-Message
GET	/auth/me	Aktuelles User-Profil lesen
GET	/journal/entries/	Journal-Einträge listen
GET	/journal/entries/{id}	Einzelnen Journal-Eintrag lesen
POST	/journal/entries/	Journal-Eintrag erstellen (mit AI-Anreicherung)
PUT	/journal/entries/{id}	Journal-Eintrag aktualisieren
DELETE	/journal/entries/{id}	Journal-Eintrag löschen
GET	/goals/	Ziele listen (priorisiert sortiert)
GET	/goals/{id}	Einzelnes Ziel lesen
POST	/goals/	Ziel erstellen
PUT	/goals/{id}	Ziel aktualisieren
DELETE	/goals/{id}	Ziel löschen
POST	/goals/recommend	KI-basierte Zielempfehlungen abrufen
POST	/goals/enhance-description	KI-gestützte Beschreibungs-Verbesserung
POST	/ai/chat/	Kontextueller Chatbot-Dialog
POST	/ai/journal-question/	Reflexionsfrage generieren
GET	/analytics/trends/	Zeitreihen-Trends (Moving Averages)
GET	/analytics/stats/	Durchschnittswerte und Streak
GET	/analytics/correlations/	Korrelationen + KI-Insights
GET	/analytics/summary/	KI-generierte Zusammenfassung der Periode

Methode	Pfad	Zweck
GET	/admin/stats	System-Statistiken (admin-only)

3.3 Auth-Endpoints

3.3.1 GET /auth/me - Aktuelles Profil lesen

Feld	Wert
Beschreibung	Liefert das User-Profil des authentifizierten Aufrufers. Erzeugt den User just-in-time, falls er noch nicht lokal existiert.
HTTP-Methode	GET
Pfad	/auth/me
Authentifizierung	JWT (Bearer)

Response (200)

```
{
  "id": 42,
  "email": "user@example.com",
  "is_admin": false,
  "created_at": "2026-05-22T10:14:33Z"
}
```

HTTP-Statuscodes

Code	Bedeutung
200	Erfolgreiche Verarbeitung
401	Fehlende oder ungültige Authentifizierung
422	Validierungsfehler (Pydantic / FastAPI)
500	Unerwarteter Serverfehler

Fachliche Business-Logik

- Verifikation des Bearer-Tokens gegen die Cognito-JWKS.
- Lookup des Nutzers über cognito_sub.
- Falls nicht vorhanden: INSERT in users (Just-in-Time Provisioning).
- Falls E-Mail im Token aktueller als im DB-Record: Update auf users.email.

3.4 Journal-Endpoints

3.4.1 GET /journal/entries/ - Einträge listen

Feld	Wert
Beschreibung	Listet alle Journal-Einträge des aktuellen Nutzers, sortiert nach date DESC, dann created_at DESC.
HTTP-Methode	GET

Feld	Wert
Pfad	/journal/entries/
Authentifizierung	JWT

Query-Parameter

Parameter	Typ	Pflicht	Beschreibung
skip	int (>=0)	nein	Offset für Pagination (Default 0)
limit	int (1-100)	nein	Max. Anzahl Treffer (Default 100)

Response (200, Auszug)

```
[
  {
    "id": 7,
    "title": "Reflections on My Day",
    "date": "2026-05-16",
    "content": "Today was productive...",
    "sentiment_level": 4,
    "sleep_quality": 3,
    "stress_level": 2,
    "social_engagement": 3,
    "formatted_content": "***Morning** ...",
    "activities": "Morning run, Reading",
    "sentiments": "Content, Grateful",
    "created_at": "2026-05-16T19:42:01Z",
    "updated_at": "2026-05-16T19:42:18Z",
    "goals": [ { "id": 2, "title": "Take long walks", "..." } ]
  }
]
```

3.4.2 GET /journal/entries/{id} - Einzelnen Eintrag lesen

Feld	Wert
Beschreibung	Lädt einen Eintrag inklusive zugeordneter Ziele. 404, wenn der Eintrag nicht zum Nutzer gehört.
HTTP-Methode	GET
Pfad	/journal/entries/{id}
Authentifizierung	JWT

Path-Parameter

Parameter	Typ	Pflicht	Beschreibung
id	int	ja	Primärschlüssel des Eintrags

HTTP-Statuscodes

Code	Bedeutung
200	Erfolgreiche Verarbeitung

Code	Bedeutung
401	Fehlende oder ungültige Authentifizierung
422	Validierungsfehler (Pydantic / FastAPI)
500	Unerwarteter Serverfehler
404	Eintrag nicht gefunden oder gehört nicht zum Nutzer

3.4.3 POST /journal/entries/ - Eintrag erstellen

Feld	Wert
Beschreibung	Erstellt einen neuen Eintrag. Triggert anschließend asynchron die KI-Anreicherung via BackgroundTask (enrich_journal_entry).
HTTP-Methode	POST
Pfad	/journal/entries/
Authentifizierung	JWT

Request-Body

```
{
  "title": "Reflections on My Day",
  "date": "2026-05-16",
  "content": "Today was productive. I finished a major task and took a long walk.",
  "sentiment_level": 4,
  "sleep_quality": 3,
  "stress_level": 2,
  "social_engagement": 3
}
```

Validierungsregeln

- Pflichtfelder: title, date, content.
- Skalen-Werte (sentiment_level, sleep_quality, stress_level, social_engagement) sind IntEnum 1-5, optional.
- date als ISO-8601 Date (YYYY-MM-DD).
- title, content als Strings ohne explizite Längenbegrenzung (Empfehlung: serverseitig ergänzen).

Response (200)

```
{
  "id": 23,
  "title": "Reflections on My Day",
  "date": "2026-05-16",
  "content": "Today was productive...",
  "sentiment_level": 4,
  "sleep_quality": 3,
  "stress_level": 2,
  "social_engagement": 3,
  "formatted_content": "Today was productive...",
  "activities": "",
  "sentiments": ""
}
```



```

"created_at": "2026-05-22T10:14:33Z",
"updated_at": null,
"goals": []
}

```

HTTP-Statuscodes

Code	Bedeutung
200	Erfolgreiche Verarbeitung
401	Fehlende oder ungültige Authentifizierung
422	Validierungsfehler (Pydantic / FastAPI)
500	Unerwarteter Serverfehler

Fachliche Business-Logik

- Synchron: INSERT in `journal_entries` mit `user_id`, gesetzten Skalen-Enums (`.value`), `formatted_content` initial = `content`.
- Asynchron (BackgroundTask): `get_goal_info(user_id)` holt alle Ziele -> `analyze_entry(content, goals)` ruft das LLM auf.
- Das LLM liefert `formatted_content`, `activities`, `sentiments`, `goal_ids`. Diese werden gesetzt, `get_goals(goal_ids)` verknüpft sie via Association-Tabelle.
- `updated_at` wird auf den Anreicherungszeitpunkt gesetzt; AI-Aufruf erzeugt `ai_usage_logs`-Eintrag.

Beispielablauf

- Client sendet POST `/journal/entries/` mit Bearer-Token.
- Server validiert Token (Cognito JWKS), lädt/legt User an.
- CRUD speichert Eintrag, Response wird sofort an Client zurückgegeben.
- BackgroundTask startet, ruft Gemini/z.ai mit Eintrag und Ziel-Kontext auf.
- Eintrag wird mit KI-Resultaten aktualisiert (`formatted_content`, `activities`, `sentiments`, `goals`).
- Bei Folgeabruf (GET) erhält der Client die angereicherten Daten.

3.4.4 PUT `/journal/entries/{id}` - Eintrag aktualisieren

Feld	Wert
Beschreibung	Aktualisiert einen vorhandenen Eintrag. Triggert die AI-Anreicherung erneut, falls sich <code>content</code> geändert hat.
HTTP-Methode	PUT
Pfad	<code>/journal/entries/{id}</code>
Authentifizierung	JWT

Request-Body (alle Felder optional)

```

{
  "title": "Reflections on My Day",
  "date": "2026-05-16",
  "content": "Today was productive.",
}

```

```

"sentiment_level": 4,
"sleep_quality": 3,
"stress_level": 4,
"social_engagement": 3
}

```

Fachliche Business-Logik

- Lookup Eintrag inkl. user_id-Filter (Mandantentrennung).
- model_dump(exclude_unset=True) -> Partial Update.
- updated_at = now(UTC).
- Wenn content im Update enthalten war: erneute Background-Anreicherung.

HTTP-Statuscodes

Code	Bedeutung
200	Erfolgreiche Verarbeitung
401	Fehlende oder ungültige Authentifizierung
422	Validierungsfehler (Pydantic / FastAPI)
500	Unerwarteter Serverfehler
404	Eintrag nicht gefunden

3.4.5 DELETE /journal/entries/{id} - Eintrag löschen

Feld	Wert
Beschreibung	Hartes Löschen des Eintrags. Verknüpfungen in journal_goal_association sind über SQLAlchemy-Cascading nicht explizit konfiguriert (siehe Kapitel 9).
HTTP-Methode	DELETE
Pfad	/journal/entries/{id}
Authentifizierung	JWT

Response (200)

```
{ "message": "Journal entry with id 7 deleted successfully" }
```

HTTP-Statuscodes

Code	Bedeutung
200	Erfolgreiche Verarbeitung
401	Fehlende oder ungültige Authentifizierung
422	Validierungsfehler (Pydantic / FastAPI)
500	Unerwarteter Serverfehler
404	Eintrag nicht gefunden

3.5 Goal-Endpoints

3.5.1 GET /goals/ - Ziele listen

Feld	Wert
Beschreibung	Listet alle Ziele des Nutzers, sortiert nach Priorität (High, Medium, Low). Verknüpfte Einträge werden auf max. 5 jüngste reduziert (max_entries_per_goal).
HTTP-Methode	GET
Pfad	/goals/
Authentifizierung	JWT

Query-Parameter

Parameter	Typ	Pflicht	Beschreibung
skip	int (>=0)	nein	Offset, Default 0
limit	int (1-100)	nein	Limit, Default 100

3.5.2 GET /goals/{id} - Einzelnes Ziel

Feld	Wert
Beschreibung	Lädt ein Ziel inklusive max. 5 jüngsten verknüpften Einträgen. 404 bei Nicht-Existenz / Fremdzugriff.
HTTP-Methode	GET
Pfad	/goals/{id}
Authentifizierung	JWT

3.5.3 POST /goals/ - Ziel erstellen

Feld	Wert
Beschreibung	Legt ein neues Ziel an. progress wird initial mit 0 gesetzt.
HTTP-Methode	POST
Pfad	/goals/
Authentifizierung	JWT

Request-Body

```
{
  "title": "Take long walks",
  "type": "Recurring",
  "category": "Health",
  "priority": "Medium",
  "description": "Taking long walks is good for your health.",
  "targetDate": "2026-12-31"
}
```

Validierungsregeln

- Pflichtfelder: title, type, category, priority.
- priority ist Enum 'High' | 'Medium' | 'Low'.
- targetDate (alias target_date) als ISO-Date, optional.
- populate_by_name = True erlaubt sowohl 'targetDate' (Frontend-Convention) als auch 'target_date'.

3.5.4 PUT /goals/{id} - Ziel aktualisieren

Feld	Wert
Beschreibung	Partielles Update eines Ziels inklusive optionalem progress (0-100).
HTTP-Methode	PUT
Pfad	/goals/{id}
Authentifizierung	JWT

Request-Body (Auszug)

```
{
  "title": "Complete Python Course",
  "type": "One-time",
  "target_date": "2026-06-30",
  "category": "Education",
  "priority": "Medium",
  "description": "Finish the Python course.",
  "progress": 60
}
```

Fachliche Business-Logik

- model_dump(exclude_unset=True) -> Partial Update.
- priority wird als Enum-Value (.value) gespeichert.
- updated_at = now(UTC).
- Hinweis: Es existiert keine serverseitige Validierung, ob progress in [0, 100] liegt; sollte ergänzt werden.

3.5.5 DELETE /goals/{id}

Feld	Wert
Beschreibung	Hartes Löschen eines Ziels.
HTTP-Methode	DELETE
Pfad	/goals/{id}
Authentifizierung	JWT

Response (200)

```
{ "message": "Goal with id 7 deleted successfully" }
```

3.5.6 POST /goals/recommend - KI-Zielvorschläge

Feld	Wert
Beschreibung	Liest die jüngsten Einträge, konsolidiert deren Inhalte und liefert eine LLM-generierte Liste empfohlener Ziele.
HTTP-Methode	POST
Pfad	/goals/recommend
Authentifizierung	JWT

Response (200)

```
[
  {
    "title": "Develop a weekly stress management routine",
    "description": "Set aside time each week for activities that reduce stress.",
    "category": "Health"
  }
]
```

Fachliche Business-Logik

- Aggregation der entry.content-Felder zu einem Prompt-Kontext.
- LLM-Aufruf recommend_goals -> JSON-Parse -> RecommendedGoalList.
- AI-Log wird erzeugt; bei 0 Einträgen leere Liste.

3.5.7 POST /goals/enhance-description

Feld	Wert
Beschreibung	Verbessert oder generiert eine Zielbeschreibung anhand des Titels und einer optionalen Bestehenden.
HTTP-Methode	POST
Pfad	/goals/enhance-description
Authentifizierung	JWT

Request-Body

```
{
  "title": "Run 5 km without stopping",
  "description": "Start training plan"
}
```

Response (200)

```
"Build endurance step by step with a structured plan, starting with short intervals and gradually progressing to a continuous 5 km run."
```

3.6 AI-Endpoints

3.6.1 POST /ai/chat/ - Kontextbezogener Chatbot

Feld	Wert
Beschreibung	Sendet eine Nutzernachricht an einen LLM-Assistenten mit System-Prompt und Nutzerkontext (max. 10 Ziele + 10 jüngste Einträge).
HTTP-Methode	POST
Pfad	/ai/chat/
Authentifizierung	JWT

Request-Body

```
{ "message": "How have I been feeling this week?" }
```

Response (200)

```
{ "text": "Looking back at your last entries, you sound..." }
```

Fachliche Business-Logik

- System-Prompt definiert Tonalität, Datenschutz-Regeln und Funktionen des Assistenten.
- Kontext-Block enthält Goals (Titel, Priorität, Target, Beschreibung) und Einträge (Datum, Titel, Content).
- Antwort wird als JSON mit Feld 'text' erwartet (response_format json_object).

3.6.2 POST /ai/journal-question/ - Reflexionsfrage

Feld	Wert
Beschreibung	Generiert eine offene, einzelne Reflexionsfrage zu einem in Arbeit befindlichen Eintrag.
HTTP-Methode	POST
Pfad	/ai/journal-question/
Authentifizierung	JWT

Request-Body

```
{ "content": "Heute war anstrengend, aber ich habe viel geschafft." }
```

Response (200)

```
{ "question": "Welcher Moment hat dich heute am meisten beansprucht?" }
```

3.7 Analytics-Endpoints

3.7.1 GET /analytics/trends/ - Zeitreihen-Trends

Feld	Wert
Beschreibung	Liefert Moving-Average-Zeitreihen für Sentiment, Sleep, Stress, Social über die gewählte Periode.
HTTP-Methode	GET
Pfad	/analytics/trends/
Authentifizierung	JWT

Query-Parameter

Parameter	Typ	Pflicht	Beschreibung
period	string	nein	z. B. '7days', '30days', '6months', '1years'. Default '30days'.

Response (200)

```
{
  "dates": ["2026-04-22", "2026-04-23", "..."],
  "sentiment": [4, 4, 3, "..."],
  "sleep": [3, 3, 4, "..."],
  "stress": [2, 2, 3, "..."],
  "social": [3, 3, 3, "..."]
}
```

Fachliche Business-Logik

- Filterung der Einträge auf $\geq$ cutoff_date (UTC).
- Window-Size automatisch: $\min(21, \max(3, \text{past_days} // 7))$.
- Fehlende Skalen-Werte werden mit Default 3 ersetzt (Neutralwert).
- Ausgabe als gerundete Integer (round).

3.7.2 GET /analytics/stats/ - Durchschnitte und KPIs

Feld	Wert
Beschreibung	Liefert Durchschnitte, Gesamtzahl der Einträge, aktuellen Streak und durchschnittliche Wortanzahl pro Eintrag.
HTTP-Methode	GET
Pfad	/analytics/stats/
Authentifizierung	JWT

Response (200)

```
{
  "sentiment": 3.7,
  "sleep": 3.2,
  "stress": 2.8,
  "social": 3.1,
  "total_entries": 24,
}
```

```

"current_streak": 5,
"average_words_per_entry": 142.3
}

```

Fachliche Business-Logik

- Durchschnitte ignorieren NULL-Werte (None) auf den Skalen.
- current_streak: zählt rückwärts ab heute (UTC-Date), solange entry.date in der Menge enthalten ist.
- Lookback für Streak-Berechnung: max. 365 Tage.

3.7.3 GET /analytics/correlations/ - Korrelationen + KI-Insights

Feld	Wert
Beschreibung	Berechnet Pearson-Korrelationen zwischen Skalen, liefert die 2 stärksten und erzeugt im Hintergrund KI-Insights.
HTTP-Methode	GET
Pfad	/analytics/correlations/
Authentifizierung	JWT

Response (200, gekürzt)

```

{
  "strongest_correlations": {
    "sleep_sentiment": {
      "correlation": 0.72,
      "data": [ {"date": "2026-05-01", "x": 4, "y": 4}, "..."],
      "x_label": "Sleep Quality",
      "y_label": "Sentiment Level",
      "x_avg": [3.3, 3.5, "..."],
      "y_avg": [3.5, 3.8, "..."],
      "insights": ["Better sleep correlates with...", "Tip: ...", "Action: ..."]
    }
  },
  "total_data_points": 18
}

```

Fachliche Business-Logik

- Aufbau eines aligned-Datensatzes nur für Einträge mit allen vier Skalenwerten.
- Berechnung von 6 Paarkorrelationen via numpy.corrcoef.
- Sortierung nach |r| desc, Auswahl der Top-2.
- Cache-Lookup: bei Hit (TTL 24h) Sofortantwort, sonst Stub mit leeren insights + BackgroundTask zur Berechnung.
- Bei < 2 Datenpunkten: Hinweis-Message statt Daten.

3.7.4 GET /analytics/summary/ - KI-Zusammenfassung

Feld	Wert
Beschreibung	Generiert (oder liest aus Cache) eine narrative Zusammenfassung der Periode mit emotionalen Mustern und Themen.

Feld	Wert
HTTP-Methode	GET
Pfad	/analytics/summary/
Authentifizierung	JWT

Response (200)

```
{ "summary": "Over the past entries, you reflected deeply on..." }
```

Fachliche Business-Logik

- Cache-Hit: Rückgabe aus AnalyticsCache.
- Cache-Miss: Stub-Response 'Generating insights... Check back shortly.' + BackgroundTask.
- Background: prepare_summary_data -> summarize_journal_entries -> _set_cache.
- Bei 0 Einträgen: explizite Meldung 'No journal entries found for the specified period.'

3.8 Admin-Endpoints

3.8.1 GET /admin/stats

Feld	Wert
Beschreibung	Liefert systemweite Kennzahlen zur Plattform. Erfordert is_admin = true im User-Record.
HTTP-Methode	GET
Pfad	/admin/stats
Authentifizierung	JWT + Admin-Rolle

Response (200)

```
{
  "total_users": 312,
  "active_users_7d": 84,
  "total_entries": 4218,
  "total_ai_calls": 9341,
  "ai_success_rate": 98.7,
  "ai_calls_today": 142,
  "ai_tokens_total": 1820431
}
```

Fachliche Business-Logik

- active_users_7d: distinct user_id aus journal_entries mit created_at >= now() - 7d.
- ai_success_rate = (success=true) / total_ai_calls * 100, gerundet auf 1 Nachkommastelle.
- ai_calls_today: created_at >= today_start (00:00 UTC).
- ai_tokens_total: COALESCE(SUM(input_tokens), 0) + COALESCE(SUM(output_tokens), 0).

HTTP-Statuscodes

Code	Bedeutung
200	Erfolgreiche Verarbeitung
401	Fehlende oder ungültige Authentifizierung
422	Validierungsfehler (Pydantic / FastAPI)
500	Unerwarteter Serverfehler
403	Authentifiziert, aber nicht Admin

4. Business-Logik und Zustandsmodell

4.1 Zentrale Geschäftsprozesse

- Eintrags-Lifecycle: Erstellung -> KI-Anreicherung -> optionale Updates -> Löschung.
- Ziel-Lifecycle: Anlage -> Pflege (Beschreibung, Priorität, progress) -> Verknüpfung mit Einträgen via KI -> Abschluss/Löschung.
- Analytics-Lifecycle: Anfrage -> Cache-Lookup -> Direktantwort oder Stub + Background-Berechnung -> Cache-Schreiben.
- AI-Aufrufzyklus: Aufruf -> Retry (bei 429/5xx) -> Erfolg/Fehler -> Logging in ai_usage_logs.

4.2 Zustand JournalEntry

Der Eintrag besitzt keinen expliziten Status-Spalten, jedoch implizite Zustände, abgeleitet aus den befüllten Anreicherungsfeldern.

Zustand (implizit)	Charakteristik
CREATED	Eintrag persistiert, formatted_content == content, activities und sentiments leer, goals leer.
ENRICHING	BackgroundTask läuft. Datenbank-seitig nicht direkt sichtbar (keine Status-Spalte).
ENRICHED	formatted_content angereichert, activities und sentiments befüllt, ggf. goals verknüpft, updated_at != null.
ENRICHMENT_FAILED	Logged in App-Logger, Eintrag verbleibt im CREATED-Zustand. Kein Retry-Mechanismus.

4.2.1 Zustandsübergänge

Aktueller Zustand	Trigger	Neuer Zustand
(nicht existent)	POST /journal/entries/	CREATED
CREATED	BackgroundTask startet	ENRICHING
ENRICHING	LLM-Aufruf erfolgreich	ENRICHED
ENRICHING	LLM-Aufruf scheitert (nach Retries)	ENRICHMENT_FAILED

Aktueller Zustand	Trigger	Neuer Zustand
ENRICHED	PUT mit Content-Änderung	ENRICHING
ENRICHED	PUT ohne Content-Änderung	ENRICHED (nur Update der Skalen)
beliebig	DELETE /journal/entries/{id}	(nicht existent)

4.3 Zustand Goal

Ziele haben keinen ausgewiesenen Lifecycle-Status. Der einzig dynamische Wert ist progress (0-100). Eine fachliche Klassifikation kann anhand von progress + target_date abgeleitet werden:

Inferierter Status	Regel
ACTIVE	progress < 100 und (target_date null oder >= heute)
COMPLETED	progress == 100
OVERDUE	progress < 100 und target_date < heute

Diese Klassifikation ist im Code nicht persistiert; sie sollte für UI-Zwecke entweder im Backend abgeleitet oder als zusätzliches Feld eingeführt werden.

4.4 Zustand AnalyticsCache

Zustand	Definition	Verhalten des Endpoints
MISS	Kein Record vorhanden	Stub-Response + BackgroundTask zur Erstberechnung
FRESH	Record vorhanden, generated_at innerhalb TTL 24h	Direktantwort aus Cache
STALE	Record vorhanden, generated_at älter als 24h	Aktuell als MISS behandelt - kein Aged-Cache-Return + asynchroner Refresh

Empfehlung: STALE separat behandeln (Stale-While-Revalidate), um bessere UX bei abgelaufenem Cache zu erzielen.

4.5 Validierungslogik

- Eingangsvalidierung über Pydantic-Schemas (JournalEntryCreate, GoalCreate, etc.).
- Enum-Bindung der Skalen (IntEnum 1-5) verhindert Out-of-Range-Werte.
- Pfad-Parameter id: int wird von FastAPI typisiert geprüft.
- Mandantentrennung: Jeder CRUD-Lookup filtert auf user_id; Fremdzugriffe führen zu 404.
- Nicht abgedeckt: Längenbeschränkungen für title/content/description, progress-Range, target_date in der Zukunft.

4.6 Fehlerfälle

Fehlerfall	Verhalten
Ungültiges/abgelaufenes JWT	HTTP 401 'Invalid or expired token', WWW-Authenticate-Header
Fehlender Token	HTTP 401 'Not authenticated'
Admin-Endpoint ohne Admin-Rechte	HTTP 403 'Admin access required'
Ressource gehört nicht zum Nutzer	HTTP 404 (nicht 403) - bewusst keine Existenz-Leakage
Pydantic-Validierungsfehler	HTTP 422 mit Feld-Details
AI-Aufruf RateLimit / 5xx	Bis zu 3 Retries mit Exponential Backoff (1s, 2s, 4s)
AI-Aufruf endgültig gescheitert	AIUsageLog mit success=false; Background-Task loggt Fehler
Cache-Schreibfehler	Wird im Background-Task geloggt, Endpoint-Antwort bleibt unberührt

4.7 Abhängigkeiten zwischen Prozessen

- Goal-Zuordnung in Einträgen hängt von der Existenz aktiver Ziele beim AI-Aufruf ab. Wenn Ziele nach der Anreicherung gelöscht werden, bleibt die Association-Tabelle dangling, bis sie explizit aufgeräumt wird (siehe Kapitel 9).
- Analytics setzen auf das Feld entry.sentiments (Komma-Liste) auf. Nicht angereicherte Einträge erscheinen nicht in der prepare_summary_data.
- Streak-Berechnung ist robust gegen fehlende Anreicherung, da sie nur auf entry.date abstellt.
- Goal Recommendations setzen auf rohen content auf, nicht auf angereicherten Inhalt.

5. Sequenz- und Datenflussbeschreibungen

5.1 Konvention textueller Sequenzdiagramme

- Akteure sind links (Client) -> Server-Komponenten (Router, Service, CRUD, AI, DB) nach rechts.
- Notation: Akteur -> Komponente : Aktion; Rückgaben mit '<-'.

5.2 Sequenz: Eintrag erstellen mit Hintergrund-Anreicherung

```

Client -> JournalRouter : POST /journal/entries/ (JWT, JSON-Body)
JournalRouter -> AuthDep : verify token + load user
AuthDep -> CognitoJWKS : GET /.well-known/jwks.json (TTL 1h)
CognitoJWKS <- AuthDep : keys
AuthDep -> UsersDB : SELECT user by cognito_sub
UsersDB <- AuthDep : user (or insert if missing)
JournalRouter -> JournalCRUD : create_journal_entry(entry_id, user_id)
JournalCRUD -> EntriesDB : INSERT journal_entries
EntriesDB <- JournalCRUD : db_entry
JournalRouter -> BackgroundTask : enrich_journal_entry(entry_id, user_id)
JournalRouter <- Client : 200 OK (JournalEntry without enrichment)

# Background path
BackgroundTask -> JournalCRUD : get_journal_entry
BackgroundTask -> GoalsDB : get_goal_info
BackgroundTask -> AIClient : analyze_entry(content, goals)
AIClient -> Gemini/Z.AI : chat.completions.create (json_object)
AIClient -> AIUsageLogsDB : INSERT ai_usage_logs (success/fail)
BackgroundTask -> EntriesDB : UPDATE formatted_content, activities, sentiments, goals

```

5.3 Sequenz: Korrelationen abrufen

```

Client -> AnalyticsRouter : GET /analytics/correlations/?period=30days
AnalyticsRouter -> AuthDep : verify token, load user
AnalyticsRouter -> CacheDB : SELECT analytics_cache (user, period,
'correlation_insights')
CacheDB <- AnalyticsRouter : cached or null

# Cache-Hit
AnalyticsRouter <- Client : 200 OK (JSON.parse(cached))

# Cache-Miss
AnalyticsRouter -> Analytics : calculate_correlations_data(past_days)
Analytics -> EntriesDB : SELECT entries WHERE date >= cutoff
Analytics <- AnalyticsRouter : result with top-2 correlations (insights = [])
AnalyticsRouter -> BackgroundTask : _generate_correlations_background
AnalyticsRouter <- Client : 200 OK (stub with empty insights)

# Background
BackgroundTask -> AIClient : generate_correlation_insights(chart_data)
BackgroundTask -> CacheDB : INSERT/UPDATE analytics_cache

```

5.4 Sequenz: Chatbot-Antwort

```
Client -> ChatbotRouter      : POST /ai/chat/ {message}
ChatbotRouter -> AuthDep      : verify token, load user
ChatbotRouter -> GoalCRUD     : get_goals(user_id, limit=10)
ChatbotRouter -> JournalCRUD  : get_journal_entries(user_id, limit=10)
ChatbotRouter -> ChatbotService : get_contextual_chatbot_response(message, context)
ChatbotService -> AIClient    : call_ai(messages=[system, user], feature='chatbot')
AIClient -> Gemini/Z.AI       : chat.completions.create
AIClient -> AIUsageLogsDB     : INSERT ai_usage_logs
ChatbotRouter <- Client      : 200 OK {text}
```

5.5 Sequenz: Admin-Statistiken

```
Client -> AdminRouter        : GET /admin/stats
AdminRouter -> AuthDep        : verify token, get_current_admin
AuthDep -> UsersDB            : SELECT user
AuthDep validates            : user.is_admin == true (else 403)
AdminRouter -> UsersDB        : COUNT(users)
AdminRouter -> EntriesDB      : COUNT(distinct user_id WHERE created_at>=7d)
AdminRouter -> EntriesDB      : COUNT(entries)
AdminRouter -> AIUsageLogsDB  : COUNT, SUM(input_tokens), SUM(output_tokens)
AdminRouter <- Client        : 200 OK { aggregated stats }
```

5.6 Datenflüsse extern

Externes System	Datenfluss
AWS Cognito	Backend lädt JWKS (HTTPS) -> verifiziert Signatur lokal. Es werden keine sensiblen User-Daten zurückgeschrieben.
Gemini / Z.AI	Backend sendet Prompts (Journal-Texte, Ziele, Skalen). Antwort = JSON. Token-Counts werden in ai_usage_logs persistiert.
Frontend (localhost:3000)	Reine HTTPS/REST-Kommunikation. CORS ist explizit auf den Origin beschränkt.